Guía de exposición · Grupo 10

Oct 25, 2026 · @Octavio

El hilo general

La exposición cuenta una sola historia: **pasamos de un modelo que se explica solo (el árbol de decisión) a modelos que necesitan técnicas externas para ser explicados, y terminamos en un proyecto real que compara esas técnicas.** Cada bloque cierra con una diapositiva de conclusión que deja una pregunta, y el bloque siguiente arranca respondiéndola.

Bloque	Quién	Diapositivas	Qué responde	Pregunta que deja
1 · Contexto	Baltasar	1 a 6	Qué es Machine Learning y por qué no alcanza con que un modelo acierte	¿Cómo aprende el árbol sus reglas a partir de los datos?
2 · Árboles de decisión	Gonzalo	7 a 13	Cómo el árbol elige sus preguntas con la entropía (ID3), con un ejemplo resuelto	¿Qué pasa cuando, para predecir mejor, usamos cientos de árboles?
3 · Explicabilidad	Alejandro	14 a 18	Por qué los ensambles son una caja negra y qué técnicas (XAI) la abren	Si las técnicas pueden no coincidir, ¿cuál conviene usar?
4 · Caso aplicado	Octavio	19 a 25	Un proyecto de la UNSJ que compara esas técnicas sobre modelos de Lengua de Señas	Cierre: conclusiones generales

El ejemplo del clima (Temperatura, Viento, actividad) aparece tres veces a propósito: Baltasar lo nombra en la diapositiva 2, Gonzalo lo resuelve con entropía y Alejandro lo reutiliza para mostrar SHAP. Eso es lo que hace que la exposición se sienta como un solo tema.

Por qué elegimos cada concepto y algoritmo

Los cuatro tienen que poder decir lo mismo: **estos conceptos y algoritmos los elegimos nosotros, investigando para armar la exposición, porque cuentan la historia de "modelo interpretable → caja negra → cómo explicarla".** No los elegimos porque sean temas de la materia. La conexión con Teoría de la Información (la entropía) es una consecuencia de esa elección, no el motivo.

Si preguntan "¿por qué eligieron esto?", la respuesta corta siempre empieza igual: *"Lo elegimos en nuestra investigación para la exposición porque…"*.

Qué elegimos	Por qué lo elegimos	Quién lo defiende
Algoritmo ID3 (Quinlan, 1986)	Es el algoritmo de árboles más didáctico: construye el árbol con la entropía de Shannon y se puede calcular a mano. Es la base de C4.5 y de la idea que usan CART y XGBoost.	Gonzalo
Ganancia de información	Es el criterio que usa ID3. La entropía sola mide la mezcla de un grupo; para elegir una pregunta hay que comparar antes y después, y eso es la ganancia.	Gonzalo
No usar C4.5 ni CART (Gini)	Mejoran a ID3 (atributos numéricos, poda, otro criterio), pero agregan complejidad sin cambiar la idea. Los nombramos como variantes.	Gonzalo
Ejemplo del clima con 6 días y 2 atributos	Tomamos 6 días de la tabla del método PRISM (apuntes de IA) para que el cálculo entre en dos diapositivas y el árbol quede chico. Con 11 días y 4 atributos el ejemplo era demasiado largo.	Gonzalo
Random Forest y XGBoost	Son los dos ensambles de árboles más usados y muestran las dos formas de combinar árboles: votar (en paralelo) o sumar corrigiendo errores (en secuencia). XGBoost además es uno de los modelos del proyecto de Octavio.	Alejandro

Qué elegimos	Por qué lo elegimos	Quién lo defiende
Las 4 técnicas: importancia de variables, SHAP, LIME y contrafactuales	Son las más citadas en la bibliografía de XAI y cubren las combinaciones: global y local, específicas de árboles y agnósticas al modelo. Son también las que compara el proyecto.	Alejandro
SHAP como ejemplo aplicado	Sirve para un caso y para el modelo completo, y en árboles se calcula exacto con TreeSHAP. El gráfico es ilustrativo, no un cálculo real.	Alejandro
Sistemas expertos (CLIPS)	Muestran que explicar no es un problema nuevo: antes las reglas las escribía una persona y se podía mostrar la traza. El problema aparece cuando las reglas se aprenden de los datos.	Baltasar
XGBoost y LSTM (caso aplicado)	No los elegimos nosotros: son los modelos ya entrenados en el proyecto de LSA de la UNSJ. Encajan porque XGBoost es un ensamble de árboles y la LSTM una red neuronal: los dos extremos de la caja negra.	Octavio

Bloque 1 · Baltasar (diapositivas 1 a 6)

Tu trabajo es plantear el problema: **los modelos aprenden solos sus reglas, y por eso después hay que poder explicar qué aprendieron.** Si eso queda claro, todo lo demás se entiende.

Diapositiva	Qué decir	Qué tenés que saber
1 · Portada	Presentar al grupo y el recorrido: por qué explicar, árboles, cajas negras y XAI, caso de la UNSJ.	El orden de los bloques y quién expone cada uno.

Diapositiva	Qué decir	Qué tenés que saber
2 · Qué es Machine Learning	La computadora aprende de ejemplos en vez de seguir reglas escritas. Cuatro pasos: datos, entrenamiento, modelo, predicción.	Atributo = característica de un ejemplo (temperatura). Clase = lo que se predice (la actividad). Modelo = lo que queda aprendido.
3 · ¿Alcanza con acertar?	Un modelo puede acertar y no poder justificarse (el dibujo de la caja negra). Explicar sirve para confianza, detectar errores y responsabilidad.	Definición de explicabilidad: dar razones comprensibles de por qué un modelo dio un resultado. Ejemplo de "atajo": acertar por un detalle irrelevante de los datos.
4 · Dónde se ubican los árboles	No supervisado (sin respuesta correcta, busca grupos) contra supervisado (con clase, predice). El árbol es supervisado.	Ejemplos de cada uno: K-Means y A Priori; Bayes, PRISM y árboles.
5 · Sistemas expertos	Antes las reglas las escribía un experto y se podía mostrar la traza. Ahora se aprenden de los datos y, en modelos grandes, no hay traza.	Qué es CLIPS y qué es la traza de ejecución (la lista de reglas que se activaron).
6 · Conclusión del bloque	Tres ideas: acertar no alcanza; el árbol es supervisado; se lee como reglas SI…ENTONCES.	La pregunta que dejás: "¿Cómo aprende el árbol esas reglas?". Ahí le pasás a Gonzalo.

Lo que eligió el grupo en tu parte: abrir con los sistemas expertos fue decisión nuestra, para mostrar que el problema de explicar no es nuevo, pero sí cambia cuando las reglas se aprenden.

Frase de pase: "Queda una pregunta: ¿cómo hace el árbol para aprender esas reglas? Para eso le paso la palabra a Gonzalo."

Bloque 2 · Gonzalo (diapositivas 7 a 13)

Tu trabajo es responder la pregunta de Baltasar: **el árbol aprende sus reglas eligiendo, en cada paso, la pregunta que más reduce la entropía.** Es el bloque con más Teoría de la Información, así que tenés que poder hacer el cálculo a mano.

Diapositiva	Qué decir	Qué tenés que saber
7 · Qué es un árbol	Clasifica con una secuencia de preguntas. Raíz, nodos, ramas y hojas. Cada camino es una regla SI…ENTONCES.	El ejemplo ¿Llueve? es ilustrativo, no sale de datos.
8 · Entropía	En cada nodo se pregunta por el atributo que más reduce la incertidumbre, medida con $H(S) = -\Sigma\, p_i \log_2 p_i$.	$H = 0$: grupo puro, se vuelve hoja. H máxima $= \log_2 k$: clases en igual proporción. Se mide en bits.
9 · Ganancia e ID3	La ganancia compara la mezcla antes y después de preguntar. Usamos ID3 porque es el más didáctico.	Ganancia = H(antes) − H(después), donde H(después) se promedia según el tamaño de cada subgrupo. Los 3 pasos de ID3.
10 · Los datos	6 días, 2 atributos (Temperatura, Viento), 2 de cada actividad. Entropía inicial 1,58 bits, la máxima.	$-(2/6)\cdot\log_2(2/6) = 0{,}528$; por 3 clases = 1,58. $\log_2 3 = 1{,}585$.
11 · Resultados	Temperatura deja dos grupos puros: ganancia 1,12. Viento deja todo mezclado: ganancia 0,67. Gana la Temperatura y es la raíz.	Caluroso (2 Fútbol, 1 Básquet) tiene H = 0,918. Pesa 3/6, así que quedan 0,46. 1,58 − 0,46 = 1,12. Viento: dos grupos con H = 0,92 cada uno, quedan 0,92, ganancia 0,67.
12 · El árbol	Se lee como 4 reglas. En la rama Caluroso se pregunta el Viento y todo queda puro (ganancia 0,92).	Por qué termina: ya no queda ningún grupo mezclado.
13 · Conclusión del bloque	La entropía elige las preguntas; el árbol es una caja blanca; pero solo es frágil.	La pregunta que dejás: "¿Qué pasa cuando usamos cientos de árboles?". Le pasás a Alejandro.

Lo que eligió el grupo en tu parte: ID3 y la ganancia de información (ver la tabla de decisiones), y el ejemplo reducido a 6 días para que se pueda seguir el cálculo en vivo.

Cómo explicar "frágil": con tan pocos datos, si cambia un solo día (por ejemplo, el día 6 pasa a ser Fútbol), la rama Caluroso ya no necesita preguntar el Viento y el árbol cambia.

Frase de pase: "Un árbol se lee fácil, pero es frágil. ¿Qué pasa si, para predecir mejor, usamos cientos? Eso lo explica Alejandro."

Bloque 3 · Alejandro (diapositivas 14 a 18)

Tu trabajo es contar una sola historia en tres pasos: **un árbol solo es frágil → se combinan muchos → el modelo predice mejor pero se vuelve una caja negra, y la XAI la abre.** Todo tu bloque es la respuesta a la pregunta de Gonzalo.

Diapositiva	Qué decir	Qué tenés que saber
14 · Del árbol al ensamble	El problema (sobreajuste, inestabilidad), la solución (combinar árboles) y el precio (ya no se puede leer).	Random Forest: árboles en paralelo con datos al azar, votan (bagging). XGBoost: árboles en secuencia, cada uno corrige el error anterior y se suman (boosting).
15 · Caja blanca y caja negra	Los modelos ordenados de más fácil a más difícil de entender. XGBoost y LSTM, los del proyecto de Octavio, están del lado difícil.	Interpretable = se entiende solo. Explicable = necesita una técnica externa. Post-hoc = se aplica después de entrenar, sin cambiar el modelo.
16 · Cuatro técnicas	Recordarlas por la pregunta que responde cada una. Global explica el modelo completo; local, una predicción.	Importancia (global), SHAP (local y global), LIME (local, puede variar entre ejecuciones), contrafactuales (local, el cambio mínimo que cambia la predicción).
17 · SHAP	Con el mismo ejemplo del clima: el Viento Fuerte empuja hacia Básquet y el calor en contra. Predicción = valor base + aportes.	Los valores de Shapley vienen de la teoría de juegos: reparten un resultado entre los jugadores según su aporte. TreeSHAP los calcula exacto en árboles. El gráfico es ilustrativo.
18 · Conclusión del bloque	Ensambles = caja negra; la XAI la abre; las técnicas pueden no coincidir.	La pregunta que dejás: "¿Qué técnica conviene usar?". Le pasás a Octavio.

Lo que eligió el grupo en tu parte: Random Forest y XGBoost como ejemplos de ensamble, las cuatro técnicas y SHAP como ejemplo aplicado (ver la tabla de decisiones).

Si te preguntan por qué SHAP y no LIME: SHAP sirve para un caso y para el modelo completo, y en árboles se calcula exacto. LIME aproxima y puede dar resultados distintos cada vez.

Frase de pase: "Si cada técnica puede dar una explicación distinta, ¿cuál conviene usar? Eso es lo que estudia el proyecto que presenta Octavio."

Bloque 4 · Octavio (diapositivas 19 a 25)

Tu trabajo es mostrar que todo lo anterior se usa en un proyecto real: **el proyecto de beca responde la pregunta que dejó Alejandro, comparando las técnicas de explicabilidad sobre los modelos de Lengua de Señas.**

Diapositiva	Qué decir	Qué tenés que saber
19 · El proyecto	Explicabilidad en modelos de LSA. Objetivo: comparar técnicas sobre XGBoost y LSTM. No se crean modelos nuevos.	Directora María Isabel Masanet, codirector Fabrizio Amaya, especialista en LSA Silvia Sáez. Se enmarca en el proyecto de ML y Deep Learning para LSA (dir. Raúl Klenzi).
20 · Dónde se usa cada parte	Recorrer los bloques: por qué explicar (Baltasar), árboles y entropía (Gonzalo), caja negra y XAI (Alejandro), comparar técnicas (el proyecto).	XGBoost no divide por entropía sino por cuánto reduce el error, pero la idea es la misma que en ID3. De esas divisiones sale la importancia de variables.
21 · Metodología	Cuatro pasos (revisión, preparación, aplicar las 4 técnicas, comparar) y cinco criterios.	Fidelidad, estabilidad, costo computacional, alcance e interpretabilidad, con la pregunta que responde cada uno. Resultado: una matriz modelo × técnica × criterio.
22 · Qué aporta	Entender en qué se apoya el modelo, diagnosticar por qué confunde señas y generar confianza en la comunidad sorda.	Conclusión del caso: explicar permite usar el sistema con confianza; comparar permite elegir bien cómo explicar.
23 · Conclusiones	Las conclusiones generales de toda la exposición.	Volver al hilo: del modelo que se explica solo al que necesita técnicas externas.

Diapositiva	Qué decir	Qué tenés que saber
24 · Bibliografía	No se lee: se deja unos segundos.	Quién propuso qué: Quinlan (ID3), Breiman (Random Forest), Chen y Guestrin (XGBoost), Ribeiro (LIME), Lundberg (SHAP y TreeSHAP), Wachter (contrafactuales).
25 · Cierre	"Muchas gracias."	Si abren preguntas, cada uno responde las de su bloque.

Lo que hay que aclarar en tu parte: a diferencia del resto, XGBoost y LSTM no los elegimos para la exposición. Son los modelos que ya existen en el proyecto de LSA. Lo que sí elegimos fue armar la exposición para que lleve hasta ellos.

Frase de apertura: "Alejandro nos dejó una pregunta: si las técnicas pueden no coincidir, ¿cuál conviene usar? Eso es lo que estudia este proyecto."

Preguntas probables

Responde quien expuso ese tema; si se traba, sigue el que tiene el bloque siguiente.

Pregunta	Responde	Respuesta corta
¿Por qué eligieron ID3 y no C4.5 o CART?	Gonzalo	Lo elegimos en nuestra investigación porque es el más didáctico: usa directamente la entropía y se calcula a mano. C4.5 y CART mejoran detalles pero siguen la misma idea.
¿Por qué la ganancia de información y no la entropía sola?	Gonzalo	La entropía mide un grupo; para elegir una pregunta hay que comparar antes y después. Esa diferencia es la ganancia.
¿Qué limitaciones tiene ID3?	Gonzalo	No maneja atributos numéricos ni datos faltantes, no poda (sobreajusta) y favorece atributos con muchos valores. C4.5 corrige eso con la razón de ganancia.

Pregunta	Responde	Respuesta corta
¿De dónde salen los datos del ejemplo?	Gonzalo	Son 6 días de la tabla del método PRISM de los apuntes de IA. Los redujimos para que el cálculo se pueda seguir.
¿Qué tiene que ver esto con Teoría de la Información?	Gonzalo	El árbol usa la entropía de Shannon: los bits que faltan para conocer la clase. Cada pregunta busca reducirlos.
¿El modelo más complejo siempre es más preciso?	Alejandro	No. Es una tendencia general, no una regla. Depende de los datos.
¿Por qué eligieron esas cuatro técnicas?	Alejandro	Son las más citadas en la bibliografía de XAI y cubren global y local. Además son las que compara el proyecto de Octavio.
¿Los valores del gráfico de SHAP son reales?	Alejandro	No, es un esquema ilustrativo para mostrar cómo se lee.
¿XGBoost usa entropía?	Octavio	No exactamente: divide según cuánto reduce el error. La lógica de elegir la división que más mejora es la misma de ID3.
¿Por qué XGBoost y LSTM?	Octavio	Son los modelos ya entrenados en el proyecto de LSA. Cubren los dos tipos de caja negra: un ensamble de árboles y una red neuronal.
¿Qué resultados tiene el proyecto?	Octavio	Está en curso: el resultado esperado es la matriz comparativa y las recomendaciones. No hay que inventar números.

Ayuda memoria

Concepto	En una línea
Machine Learning	La computadora aprende reglas a partir de ejemplos.
Aprendizaje supervisado	Los ejemplos traen la respuesta correcta (la clase).

Concepto	En una línea
Árbol de decisión	Clasifica con preguntas; cada camino es una regla SI…ENTONCES.
Entropía	Bits que faltan, en promedio, para saber la clase. 0 = grupo puro.
Ganancia de información	Cuánto baja la entropía al hacer una pregunta.
ID3	Pregunta siempre por el atributo de mayor ganancia, hasta que todo sea puro.
Sobreajuste	El modelo memoriza los datos y falla con casos nuevos.
Random Forest	Muchos árboles en paralelo que votan.
XGBoost	Muchos árboles en secuencia; cada uno corrige al anterior.
LSTM	Red neuronal que procesa secuencias (movimientos en el tiempo).
Caja blanca / caja negra	Se entiende sola / necesita una técnica externa.
XAI y post-hoc	Técnicas que explican un modelo ya entrenado, sin cambiarlo.
Global / local	Explica el modelo completo / una sola predicción.
SHAP	Reparte una predicción en aportes de cada variable.
LIME	Imita al modelo cerca de un caso con un modelo simple.
Contrafactual	El cambio mínimo que cambiaría la predicción.